

#### МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение высшего образования

## «МИРЭА – Российский технологический университет» РТУ МИРЭА

ИКБ направление «Киберразведка и противодействие угрозам с применением технологий искусственного интеллекта» 10.04.01

Кафедра КБ-4 «Интеллектуальные системы информационной безопасности»

## Практическая работа №4

по дисциплине

«Анализ защищенности систем искусственного интеллекта»

Группа: ББМО-01-22 Выполнил: Богомолов В.И.

Проверил: Спирин А.А.

## Выполнение работы:

#### Загружаем пакет art

```
Collecting adversarial-robustness-toolbox
Downloading adversarial_robustness_toolbox-1.6.0-py3-none-any.whl (1.6 MB)

Requirement already satisfied: numpy=1.18.0 in /usr/local/lib/python3.10/dist-packages (from adversarial-robustness-toolbox) (1.23.5)
Requirement already satisfied: scipy=1.4.1 in /usr/local/lib/python3.10/dist-packages (from adversarial-robustness-toolbox) (1.11.3)
Collecting scikit-learn(1.2.0, >=0.2.2.2 (from adversarial-robustness-toolbox)
Downloading scikit_learn-1.1.3-cp310-cp310-manylinux 2 17_x86_64.manylinux2014_x86_64.whl (30.5 MB)

Requirement already satisfied: six in /usr/local/lib/python3.10/dist-packages (from adversarial-robustness-toolbox) (1.16.0)
Requirement already satisfied: stutpools in /usr/local/lib/python3.10/dist-packages (from adversarial-robustness-toolbox) (6.7.2)
Requirement already satisfied: tquitools in /usr/local/lib/python3.10/dist-packages (from adversarial-robustness-toolbox) (4.66.1)
Requirement already satisfied: tquitools in /usr/local/lib/python3.10/dist-packages (from scikit-learn12.0, >=0.22.2-vadversarial-robustness-toolbox) (1.3.2)
Requirement already satisfied: threadpoolct)-2.0.0 in /usr/local/lib/python3.10/dist-packages (from scikit-learn12.0, >=0.22.2-vadversarial-robustness-toolbox) (3.2.0)
Installing collected packages: scikit-learn adversarial-robustness-toolbox
Attempting uninstall scikit-learn
Found existing installation: scikit-learn 1.2.2
Uninstalling scikit-learn1.2.2:
Successfully uninstalled scikit-learn-1.2.2
ERROR: pip's dependency resolver does not currently take into account all the packages that are installed. This behaviour is the source of the following dependency conflicts. bigframes 0.10.0 requires scikit-learn=1.2.2, but you have scikit-learn 1.1.3 which is incompatible.
Successfully installed adversarial-robustness-toolbox-1.16.0 scikit-learn-1.1.3
```

## Загружаем необходимые библиотеки

```
from __future__ import absolute_import, division, print_function, unicode_literals
10
        import os, sys
        from os.path import abspath
        module_path = os.path.abspath(os.path.join('...'))
        if module_path not in sys.path:
          sys.path.append(module_path)
        import warnings
        warnings.filterwarnings('ignore')
        import tensorflow as tf
        tf.compat.v1.disable_eager_execution()
        tf.get_logger().setLevel('ERROR')
        import tensorflow.keras.backend as k
        from tensorflow.keras.models import Sequential
        from tensorflow.keras.layers import Dense, Flatten, Conv2D, MaxPooling2D, Activation, Dropout
        import numpy as np
        import matplotlib.pyplot as plt
        %matplotlib inline
        from art.estimators.classification import KerasClassifier
        from art.attacks.poisoning import PoisoningAttackBackdoor, PoisoningAttackCleanLabelBackdoor
        from art.attacks.poisoning.perturbations import add_pattern_bd
        from art.utils import load_mnist, preprocess, to_categorical
        from art.defences.trainer import AdversarialTrainerMadryPGD
```

## Загружаем датасет. Датасет MNIST. Создаем случайную выборку

```
[3] (x_raw, y_raw), (x_raw_test, y_raw_test), min_, max_ = load_mnist(raw=True)

# Случайная выборка
n_train = np.shape(x_raw)[0]
num_selection = 10000
random_selection_indices = np.random.choice(n_train, num_selection)
x_raw = x_raw[random_selection_indices]
y_raw = y_raw[random_selection_indices]
```

Выполняем предобработку данных. Задается переменная и выполняется предобработка данных

```
[4] # Отравленные данные

percent_poison = .33

x_train, y_train = preprocess(x_raw, y_raw)

x_train = np.expand_dims(x_train, axis=3)

x_test, y_test = preprocess(x_raw_test, y_raw_test)

x_test = np.expand_dims(x_test, axis=3)

# Предобработка данных

n_train = np.shape(y_train)[0]

shuffled_indices = np.arange(n_train)

np.random.shuffle(shuffled_indices)

x_train = x_train[shuffled_indices]

y_train = y_train[shuffled_indices]
```

Пишем функцию create\_model(). Создаем модель нейронной сети с определенной архитектурой

```
ý [5] # функция create_model() для создания последовательной модели из 9 слоев
        from tensorflow.keras.models import Sequential
        from tensorflow.keras.layers import Dense, Flatten, Conv2D, MaxPooling2D, Dropout
        def create model():
           # архитектура модели
           model = Sequential()
           # сверточные слои
           model.add(Conv2D(32, (3, 3), activation='relu', input_shape=(28, 28, 1)))
           model.add(Conv2D(64, (3, 3), activation='relu'))
           # пулинговый слой
           model.add(MaxPooling2D(pool_size=(2, 2)))
           # dropout слой
           model.add(Dropout(0.25))
           # выравнивающий слой
           model.add(Flatten())
           # полносвязные слои
           model.add(Dense(128, activation='relu'))
           model.add(Dropout(0.25))
           model.add(Dense(10, activation='softmax'))
           model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])
            return model
```

Создаем атаку. Определяем массив, являющийся целью атаки

```
backdoor = PoisoningAttackBackdoor(add_pattern_bd)
example_target = np.array([0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1])
pdata, plabels = backdoor.poison(x_test, y=example_target)
plt.imshow(pdata[0].squeeze())

<matplotlib.image.AxesImage at 0x7c79c78b3a00>

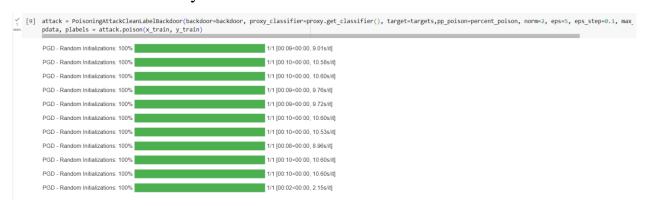
0-
5-
10-
20-
25-
0 5 10 15 20 25
```

## Определяем целевой класс атаки

#### Создаем модель. Обучаем модель



#### Выполняем атаку



Создаем отравленные примеры данных. Определяем количество данных

```
poisoned = pdata[np.all(plabels == targets, axis=1)]
poisoned_labels = plabels[np.all(plabels == targets, axis=1)]
print(len(poisoned))

idx = 0
plt.imshow(poisoned[idx].squeeze())
print(f"Label: {np.argmax(poisoned_labels[idx])}")

978
Label: 9

0-
5-
10-
20-
25-
```

## Обучим модель на отравленных данных

```
[11] model.fit(pdata, plabels, nb_epochs=10)
  Train on 10000 samples
  Epoch 1/10
        10000/10000 [=
  Epoch 2/10
  10000/10000 [
          Epoch 3/10
  Epoch 4/10
  10000/10000 [
         Epoch 5/10
         10000/10000 [
  Epoch 6/10
  Epoch 7/10
  Epoch 8/10
         10000/10000 [
  Epoch 9/10
  10000/10000 [=
        =================== - 21s 2ms/sample - loss: 0.0210 - accuracy: 0.9931
  Epoch 10/10
  10000/10000 [============] - 23s 2ms/sample - loss: 0.0174 - accuracy: 0.9942
```

Осуществим тест на чистой модели. Вычисляем точность классификации

```
// [12] clean_preds = np.argmax(model.predict(x_test), axis=1)
         clean_correct = np.sum(clean_preds == np.argmax(y_test, axis=1))
clean_total = y_test.shape[0]
         clean_acc = clean_correct / clean_total
         print("\nClean test set accuracy: %.2f%%" % (clean_acc * 100))
         # Отразим, как отравленная модель классифицирует чистую модель
         c = 0 # class to display
i = 0 # image of the class to display
c_idx = np.where(np.argmax(y_test, 1) == c)[0][i] # index of the image in clean arrays
         plt.imshow(x_test[c_idx].squeeze())
         clean_label = c
         print("Prediction: " + str(clean_preds[c_idx]))
         Clean test set accuracy: 97.92%
            5 -
           10 ·
           15
           20 -
           25
                                  10
                                            15
                                                      20
         Prediction: 0
```

# Получаем результаты атаки на модель. Отображаем изображение из атакованных данных и предсказанную метку класса

```
// [13] not_target = np.logical_not(np.all(y_test == targets, axis=1))
         px_test, py_test = backdoor.poison(x_test[not_target], y_test[not_target])
poison_preds = np.argmax(model.predict(px_test), axis=1)
         poison_correct = np.sum(poison_preds == np.argmax(y_test[not_target],
axis=1))
         poison_total = poison_preds.shape[0]
poison_acc = poison_correct / poison_total
         print("\nPoison test set accuracy: %.2f%%" % (poison_acc * 100))
         c = 0 # index to display
         plt.imshow(px_test[c].squeeze())
         plt.show()
         clean_label = c
         print("Prediction: " + str(poison_preds[c]))
         Poison test set accuracy: 1.09%
           10
           15
           20
           25
         Prediction: 9
```